Diseño Arquitectónico para Industrialización

El pipeline propuesto permite automatizar el ciclo completo del modelo, desde la lectura de datos telemáticos en tiempo real hasta la generación del “Driver Score” y su visualización teniendo la posibilidad de escalabilidad, gobernanza y reproducibilidad.

Pipeline de MLOps en AWS:

Haciendo uso de Step Functions en AWS se gestiona el entrenamiento y reentrenamiento que contiene lo siguiente:

1. Extracción y limpieza de datos desde S3 usando AWS Glue.
2. Generación de características (Feature Engineering).
3. El modelo se entrena con Scikit-learn dentro de SageMaker Training Jobs.
4. Validación automática teniendo en cuenta las métricas F1, ROC-AUC u otros según sea el caso
5. Registro del modelo y metadatos en el SageMaker Model Registry.

Para la a**utomatización** es importante tener en cuenta el tiempo, de manera que la tarea sea programada y se ejecute de forma semanal, diaria u otras.

En caso de que se detecte un cambio en los datos entonces la tarea reaccionaria a hacer un cambio en el modelo

Artefactos:

Todos los modelos, datos procesados y resultados se almacenan versionados en **S3** para trazabilidad completa.

D**espliegue e Inferencia en Tiempo Real**

El modelo es dockerizado utilizando una API REST y se publica en Amazon ECR. Luego se despliega como endpoint gestionado en Amazon SageMaker, con capacidad de autoescalado.

Los datos llegan en streaming a Amazon MSK (Kafka), donde un consumidor en Apache Flink o Kafka Streams procesa las señales telemáticas en tiempo real para generar las características de cada viaje (avg_speed, speed_volatility, hard_event_count, etc.).

Estas características se envían al endpoint de SageMaker para obtener un el Score, que luego se publica en un nuevo tópico Kafka y se almacena en Apache Druid para visualización.

Monitoreo y Reentrenamiento

La supervision del modelo se realiza de dos maneras:

AWS CloudWatch para latencia, errores, throughput u otros. Y SageMaker Model Monitor para métricas de calidad como drift en features, cambio en distribución de scores y/o degradación del modelo.

Cuando se detectan cambios significativos, se lanza automáticamente el reentrenamiento que tiene un despliegue seguro y controlado, dejando el modelo actual en producción, utilizando el 10% de la data real al nuevo modelo, en caso de superar las métricas del proceso actual, se lleva el nuevo a producción.

Analítica y Visualización (Apache Druid)

Una vez la información es modelada y se tiene resultados se hará uso de Apache Druid para crear dashboards de consumo de data en tiempo real. Estos dashboards (usando Superset o Grafana) podrían mostrar:

La información por flota, alertas sobre viajes de alto riesgo, la distribución del Driver Score por vehiculo, cliente, entre otros, los resultados históricos del modelo.

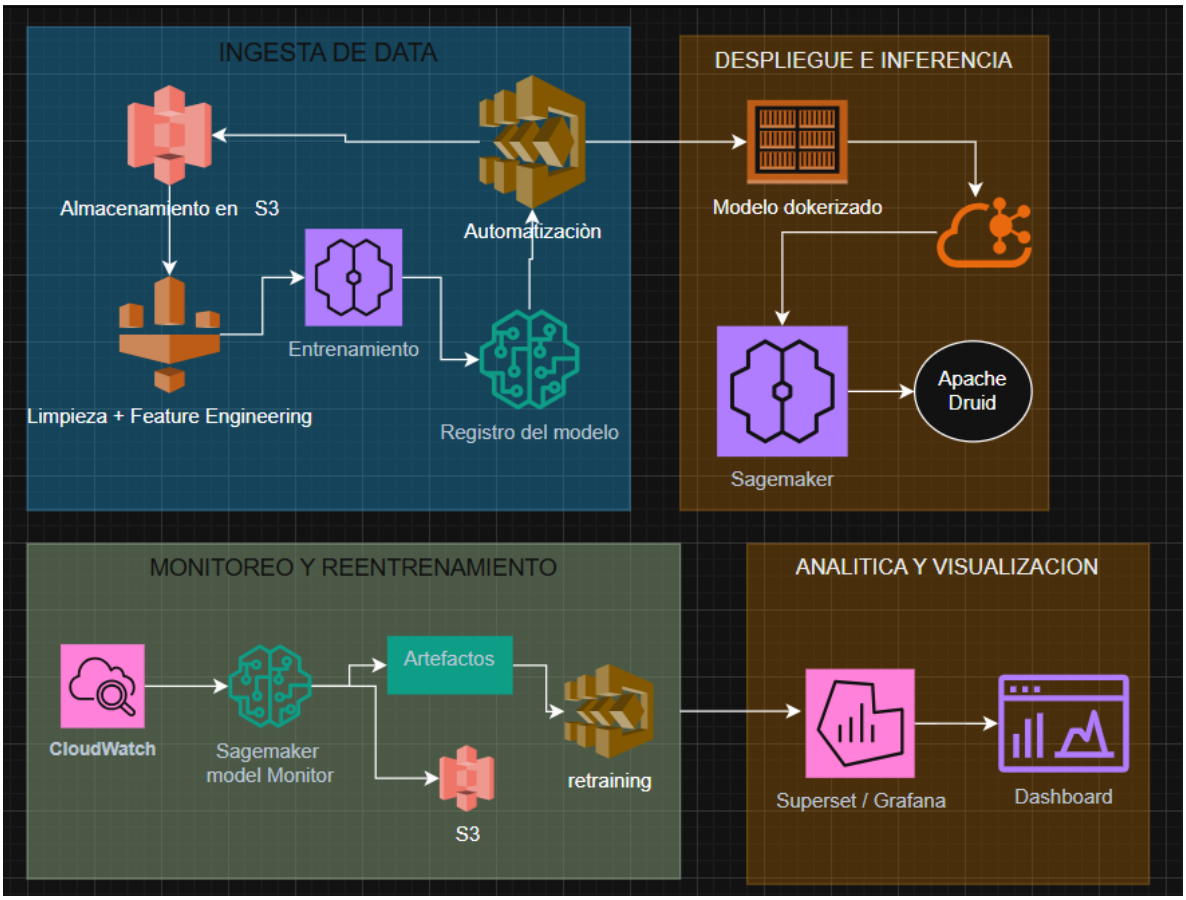
INGESTA DE DATA
Almacenamiento en S3
Automatizaciòn
Entrenamiento
Limpieza + Feature Engineering
Registro del modelo
DESPLIEGUE E INFERENCIA
Modelo dokerizado
Apache Druid
Sagemaker
MONITOREO Y REENTRENAMIENTO
CloudWatch
Sagemaker model Monitor
Artefactos
S3
retraining
ANALITICA Y VISUALIZACION
Superset / Grafana
Dashboard